

REP003 探索：既存 8 手法を、どの設定で動かせば、以後の比較の相手にできるか

W001 20261009

サマリー

以後の比較の相手にする既存 8 手法（ルールベース 3、学習ベース 5）の、パラメータ設定を決めた。評価に使う日の score を見ずに、方策の出力（入札係数 α ）が学習の長さで乱数シードでどれだけ動くかを測って候補を決め、評価に使わない日（エピソード 4～7）で試した。ルールベースは本家の既定値のまま、学習ベースは 5 手法とも 30,000 ステップ・seed 1～3 の平均とし、5 手法とも、seed による score の幅が事前に決めた 10% 以内であった（BC 0.45%～TD3_BC 9.99%）。BCQ は状態によらず $\alpha = 100$ を出しており、ここから、学習ベースの手法と一定の α の入札との差が何から来るのかを知りたい、という問いが生まれた。

1 目的

REP002 で、本家の既定設定の CQL・TD3_BC が落札できなかったことを受けて、既存 8 手法を公平に動かせるパラメータ設定を決め、以後の比較のベースラインにする。

2 実験

2.1 対象のアルゴリズム

8 手法とも、入札額を「 $\alpha \times$ 価値」で決める。設定を決めるうえで関わる点（方策がログの α に引き寄せられるか、出力に上限があるか）を、表 1 にまとめる。

表 1: 対象の 8 手法（本家の実装。設定を決めるうえで関わる点）

PID・ABid・Online LP	学習しない。規則で α を決める
BC	ログの α との二乗誤差だけで学ぶ
IQL	報酬が大きかったログの α を、重く見て真似る
TD3_BC	二乗誤差 + Q 値の項
CQL	Q 値の傾きだけで α を動かす。ログに引き寄せる項は無い
BCQ	生成モデルが α の候補を作り、Q 値が最大のものを選ぶ。出力の上限は 100

2.2 実験環境

設定は、表 2 の 4 つの条件（実験の前に決めた）を満たすように決めた。score は、セル（位置 $\times$ エピソード）ごとの「CPA のペナルティ係数 $\times$ 獲得価値」である。

表 2: 設定を決めるときの条件（「公平」の定義）

F1	評価の日（エピソード 0～3）の score で選ばない
F2	学習ベースは、出力が落ち着いた重みを使う
F3	全手法に、同じデータと同じ決め方を使う
F4	変えるのは、理屈かデータから決まるものだけ

表 3: 実験の条件

固定	学習データ：公開データ 21 日分（48,384 行） 学習率などは本家の既定、CPU, Linux
出力の測定	学習データから抜いた 2,000 状態への α 5 手法 $\times$ seed 1～3 100～50,000 ステップの 8 時点（BCQ は 20,000 まで）
落ち着きの基準	状態ごとの α の差の平均が 5 以内 （以降の時点どうし、seed どうし）
候補を試す	30,000 ステップ、seed 1～3 エピソード 4～7 $\times$ 位置 0, 8, 16, 24, 32, 40 計 90 run
合格の基準	全 seed が落札する 3 seed の平均 score の幅が、平均の 10% 以内

2.3 取った特徴量

score のほかに、方策の出力そのものと、その内訳を記録した（表 4）。

表 4: 取った特徴量

種類	記録した量
方策の出力	α の平均、時点間の差、seed 間の差、ログの α との相関、上限への集中
出力の内訳	BCQ の生成モデルの出力、TD3_BC の損失の項ごとの傾き、CQL の Q 値が最大になる α
評価	score、予算消化率、評価中の α

3 結果

決めた設定 表 5 のとおりである。ルールベース 3 手法は、本家の既定値のままにした（評価の日の score で調整していない）。学習ベース 5 手法は、学習の長さだけを変え、5 手法とも 30,000 ステップにした。30,000 は、落ち着きの基準を満たした BC・IQL の、満たし始めのステップである。設定は research/src/baseline_params.json にまとめた。

表 5: 確定したベースラインの設定（学習ベースは seed 1～3 の平均で報告する）

手法	学習の長さ	基準	但し書き
PID	—	—	既定値。調整していない
ABid	—	—	同上
Online LP	—	—	同上
BC	30,000（既定 20,000）	満たす	30,000 と 50,000 の 1 組の比較による
IQL	30,000（既定 20,000）	満たす	同上
CQL	30,000（既定 100）	満たさない	出力の水準が学習の長さで動く
TD3_BC	30,000（既定 100）	満たさない	Q 値の項が効かず、実質は BC
BCQ	30,000（既定 100）	一定の出力	状態によらず $\alpha = 100$

方策の出力 学習データの状態への α の平均は、BC・IQL・TD3_BC では、到達したあと 82～86 の範囲にあった（ログの α の平均は 82）。100 ステップの時点では、BC 5.3, IQL 0.1, CQL -0.8, TD3_BC 17.8 であった。30,000 ステップと 50,000 ステップの出力の差は、BC 4.9, IQL 4.2, TD3_BC 10.3, CQL 21.0 であった。CQL は、 α の平均が 10,000 ステップで 91, 20,000 で 101, 50,000 で 73 と動いた。TD3_BC は、方策の損失のうち Q 値の項の傾きが、二乗誤差の項の 0.1%未満であった。BCQ は、1,000 ステップ以降、3 seed と、ほぼ全状態で 100.0 を出した。生成モデルの出力そのものが上限に張り付いていた。上限をログの α の 99% 点から決めた 300 に変えると、seed 1 つは 300 に張り付き、残りの 2 つは、生成モデルの出力がログの α と負の相関（-0.42, -0.39）になったため、上限は既定の 100 のままにした。

候補を試した結果 表 6 のとおり、5 手法とも、全 seed が落札し、seed による score の幅は 10%以内であった。TD3_BC の幅は 9.99%で、基準との差は 0.01 ポイントであった。BCQ は、3 seed の結果が全セルで同じで、評価中の α は、予算が残っている間は 100.0 であった。実験の前に決めた合格の基準を、5 手法とも満たした（達成）。

表 6: 候補を試した結果（エピソード 4～7, 6 位置, 24 セルの平均 score）

	seed 1	seed 2	seed 3	平均	幅
BC	21.02	21.05	20.95	21.01	0.45%
IQL	20.08	19.47	19.29	19.61	4.0%
CQL	19.09	19.24	18.86	19.06	2.0%
TD3_BC	17.99	18.59	19.87	18.82	9.99%
BCQ	17.53	17.53	17.53	17.53	0.0%

4 結果から生まれた問い

既定の 100 ステップで落札できなかった CQL・TD3_BC は、30,000 ステップでは、全 seed が落札し、seed による score の幅が 10%以内であった。評価中の

α の平均は、BC・IQL・CQL・TD3_BC の 12 個の重みで 83～91 に収まり、ログの α の平均（82）に近かった。BCQ は、予算が残っている間、状態によらず $\alpha = 100$ を出した。24 セルの平均 score は、BC 21.0, IQL 19.6, CQL 19.1, TD3_BC 18.8, BCQ 17.5 であった。

学習ベースの 4 手法は、どれも「ログの α を真似る」のに近い方策になっていると考えられる。そうなら、手法どうしの score の差は、 α の水準のわずかな違いか、状態に応じた α の変え方の違いから来ている可能性がある。一定の α を出す BCQ が、BC の 0.83 倍の score を取っていることは、状態に応じて α を変えることの効果が、それほど大きくない可能性を示す。ただし、BCQ と BC は α の水準も違う（100 と 87）ので、この比較からは切り分けられない。また、CQL の score が学習の長さでどう変わるかは、確かめていない。

学習ベースの手法が、一定の α を出すだけの入札に対して持つ score の差は、 α の水準の違いによるのか、状態に応じて α を変えることによるのかを知りたい。