

サマリー

最終的には新しい入札方法を提案したいが、その前に、既存のルールベース手法（PID, ABid, Online LP）をこのシミュレータで動かすと何が起きるかを確認した。広告主 48 社の位置×4 エピソードで 3 手法を比べ、6 位置で主要パラメータを振ったところ、全 270 回が完走し、Online LP のスコア合計が PID の 1.92 倍、ABid の 1.49 倍で最大であった（「Online LP が最良」は論文と一致。PID と ABid の順序は論文と異なる）。1 回の評価は約 150~215 秒・約 2.5GB で、結果は再現した。ここから、Online LP の優位が報酬の大きさと CPA 制約の守り方のどちらに由来するかを知りたい、という問いが生まれた。

1 目的

既存のルールベース入札手法（PID, ABid, Online LP）が、このシミュレータでどう動くかを知る。

2 実験

2.1 対象のアルゴリズム

3 手法とも、各ティックの頭に、広告機会（PV）ごとの入札額を「 $\alpha \times$ 価値」で決める（価値は購入確率）。違いは、入札係数 α の決め方である（表 1）。

表 1: 3 手法の α の決め方（数値は既定値）

手法	見るもの	α の決め方
PID	残り予算、前のティックの支払い	最初は 15。今のペースで使い切る量が残り予算の 0.7 倍未満なら 1.2 倍、1.1 倍超なら 0.7 倍
ABid	CPA 制約、今のティックの価値	CPA 制約 $\times$ (価値 $\div$ 価値の平均)。価値が高い PV ほど強気。予算は見ない
Online LP	残り予算、早見表、CPA 制約	過去の 1 日の記録で、割安な PV から順に買ったとき、残り予算で買える境目の値段。上限は CPA 制約の 1.5 倍

2.2 実験環境

48 社のうち 1 社（プレイヤー）を対象の手法に差し替え、残りの 47 社は環境に同梱の手法のままにした（表 2）。成績は、エピソードごとの「購入数 $\times$ ペナルティ係数」（以下、score）で見る。ペナルティ係数は、実績 CPA が制約を超えたときだけ（制約 $\div$ 実績 CPA）² になり、超えなければ 1 である。

表 2: 実験の条件（1 run=1 位置 $\times$ 4 エピソード）

固定	シミュレータは既定の設定、乱数 seed=1 Windows 11, Python 3.9.25, CPU
比較	3 手法（既定のパラメータ） 位置 48 $\times$ エピソード 0~3（192 セル） 計 144 run
掃引	パラメータを 1 つずつ振る（他は既定） 位置 0, 8, 16, 24, 32, 40 $\times$ エピソード 0~3 PID: 最初の α , 上げ下げの倍率, 2 つの閾値 ABid: 全体の倍率 Online LP: α の上限, 早見表の日 計 126 run

2.3 取った特徴量

成績のほかに、あとから原因を考えるための量を、ティックごとに記録した（表 3）。

表 3: 取った特徴量

種類	記録した量
入札の強さ	実効の α （入札額の和 $\div$ 価値の和）、その順位、他 47 社の α の中央値
市場 予算のペース	最低落札価格、予算が残る広告主の数、全体の支出支払い、残り予算、PV 数、予算消化率、最後に落札したティック
落札の中身	落札数（スロット別）、露出数、価値の平均とばらつき
CPA	実績 CPA、ペナルティ係数、ペナルティ前の購入数
位置と他社 規模	予算、CPA 制約、カテゴリ、全 48 社の成績と順位 所要時間（全体、bidding() 1 回）、最大メモリ

3 結果

動作 270 run（PID 120, ABid 72, Online LP 78）が、すべて完走し、score は有限であった。1 回目には掃引の 13 run がメモリ不足で失敗した（8 並列に加えて集計を同時に走らせた）。6 並列で流し直すと、13 run とも完走した。

規模感 1 run（1 位置 $\times$ 4 エピソード）は、6~8 並列で PID 210 秒、ABid 215 秒、Online LP 204 秒（1 エピソード約 51~54 秒）で、4 並列のときは約 150 秒であった。最大メモリは 1 プロセス約 2.5GB であった。bidding() 1 回の平均は、PID 0.12ms, ABid 0.25ms, Online LP 1.66ms, 1 回の最大は 1.9ms, 2.3ms, 9.4ms であった（図 3）。




図 3: 所要時間。左: 1 エピソードのシミュレーション、右: bidding() 1 回（対数軸）

再現性 同じ設定の再実行で、episodes 表の全列




図 1: 既定設定の 3 手法の時系列 (192 セルの中央値または平均)。左: 実効入札係数 α (対数軸), 中: 支払いの累積割合, 右: 落札数




図 2: パラメータ掃引 (6 位置 $\times$ 4 エピソードの平均 score の, 既定値に対する比。横軸は振った値)

が全エピソードで完全に一致した (報酬 $\cdot$ score の差は 0.0)。

3 手法の比較 表 4 と図 4 のとおり, Online LP の score 合計は, PID の 1.92 倍, ABid の 1.49 倍で最大であった (論文の「Online LP が最良」と同じ向き)。なお, 論文の図 10 (目視の概算) では PID は ABid の 2~3.5 倍, Online LP は 6~7 倍であり, 本結果 (PID 0.78 倍, Online LP 1.49 倍) とは, PID と ABid の順序と倍率が一致しない (原因は未確認)。セル単位で Online LP が PID を上回った割合は 0.77, ABid を上回った割合は 0.69, PID が ABid を上回った割合は 0.42 であった。6 カテゴリごと, 4 エピソードごとの合計は, すべて Online LP が最大であった。プレイヤー以外の 47 社の平均スコアは, 手法によらず 21.3~21.4 でほぼ同じであった。

表 4: 既定設定の 3 手法 (48 位置 $\times$ 4 エピソード, 192 セル)

	ABid	PID	Online LP
score 合計 ($\div 20000$)	0.165	0.128	0.246
ABid を 1.0 とした値	1.00	0.78	1.49
平均報酬 (ペナルティ前)	25.8	24.4	28.7
ペナルティが掛かったセルの割合	0.85	0.82	0.39
予算消化率の平均	0.93	0.99	0.75
最終ティックより前に落札が止まった割合	0.81	0.56	0.41
順位の中央値	32	35	18




図 4: 3 手法のスコア。左: 合計, 右: セルごとの分布 (symlog 軸)

図 1 は, 実効入札係数 α (入札額の和 $\div$ 価値の和) などの時系列である。PID はティック 0 の α が 15 で (他 47 社の中央値は 68), 落札数が 0 から立ち上がるのはティック 7 ごろ以降であった。ABid はティック 0~20 の α が約 115 で, ティック 23 以降の中央値は 0 であった。Online LP は全ティックで 70~89 に収まり, 他 47 社の中央値に近かった。

パラメータ掃引 図 2 のとおり, 振った範囲で最良点が既定値だったのは, Online LP の 2 つのパラメータだけであった。既定値に対する最良点の比は, PID で 1.02~1.18 (up_factor を 1.2 から 1.1 にすると 1.18), ABid で 1.39 (bid_scale を 1 から 0.5 にすると), Online LP で 1.00 であった。ABid は入札倍率を 0.25 にすると 0.45 倍, 4 にすると 0.14 倍に落ちた。同じ 6 位置で,

既定の Online LP は 23.4, PID の最良点は 18.2, ABid の最良点は 17.0 であった。

特徴量 episodes (1,028 行), ticks (49,344 行), agents (49,344 行) の全数値列に, NaN・無限大はなかった。

以上より, 実験の前に決めた達成条件 (REP001.md) をすべて満たし, 探索の目的は**達成**した。

4 結果から生まれた問い

この環境で, ルールベース 3 手法は, 広告主の位置を変えても完走し, Online LP のスコアが最大であった。Online LP は, ペナルティが掛かったセルの割合が小さく (0.39), 同時にペナルティ前の平均報酬も最大であった (28.7)。PID と ABid は, 既定値より良くなる設定があった (最大 1.39 倍) が, その最良点でも, 既定の Online LP には届かなかった。1 回の評価は, 約 150~215 秒・約 2.5GB であり, 手法の計算時間はコンペの制限に対して十分に小さかった。

まだ確かめていないが, Online LP の優位は, CPA 制約を守ること (ペナルティが小さいこと) による部分が大きいと考えられる。一方で, PID の序盤の落札の遅れ (初期 α が低い) や, ABid の予算切れの早さが, PID と ABid の成績を下げている可能性もある。また, Online LP は早見表を使うので, 早見表の作られた条件が評価の環境と近いことが, 成績に効いている可能性がある (確認していない)。この環境での手法間の差を, ペナルティ前の報酬と, ペナルティ係数のどちらがどれだけ説明するのかを知りたい。

REP002 探索：既存の学習ベース入札手法は、この環境でどう動くか

W001 20261008

サマリー

既存の学習ベース入札手法 (BC, IQL, CQL, BCQ, TD3.BC) が、このシミュレータでどう動くかを確認し、ルールベース 3 手法と並べたベースラインを作った。公開データ 21 日分 (約 77GB) を取得して本家の既定設定で学習し直し、REP001 と同じ 48 位置×4 エピソードで評価したところ、全 17 モデル・全 486 run が完了し、スコア合計は Online LP, BCQ, BC, IQL, ABid, PID の順であった (ABid を 1.0 として 1.51, 1.41, 1.40, 1.39, 1.00, 0.78)。CQL と TD3.BC は、既定の 100 ステップの学習では落札できずスコアがほぼ 0 で、20,000 ステップでは他の学習ベースと同じ水準になった。ここから、学習ステップ数をどこまで増やせば成績が安定するのを知りたい、という問いが生まれた。

1 目的

既存の学習ベース入札手法 (BC, IQL, CQL, BCQ, TD3.BC) が、このシミュレータでどう動くかを知り、ルールベース 3 手法 (REP001) と並べたベースラインを作る。

2 実験

2.1 対象のアルゴリズム

5 手法とも、ルールベースと同じく、入札額を「 $\alpha \times$ 価値」で決める。 α は、過去の入札の記録 (ログ) から学習したニューラルネットワークに、そのティックの状態を入れて出す。入力と出力は 5 手法で同じで、違いはログからの学ばせ方である (表 1)。

表 1: 学習ベース 5 手法 (上: 共通の作り, 下: 学ばせ方の違い)

入力 (状態)	16 個の数: 残り時間, 残り予算の割合, 入札額・落札率・価値などの平均 (全体と直近), PV 数。CPA 制約は入らない
出力 学習の報酬	α を 1 つ 露出した PV の価値の和 (期待購入数)。CPA のペナルティは入らない
BC	ログの「この状態で、この α 」をそのまま真似る。報酬は見ない
IQL	その後の報酬が大きかったログの α を、重く見て真似る
CQL	報酬の見込み (Q 値) が高い α を選ぶ。ログにない α は低く見積もる
BCQ	ログに出てきそうな α の候補を作り、Q 値が最大のものを選ぶ
TD3.BC	Q 値が高い向きに α を動かす。ログの α から離れると罰を受ける

2.2 実験環境

公開データで学習し直した重みを、REP001 と同じ方法 (48 社のうち 1 社を差し替え, score も同じ定義) で評価した (表 2)。REP001 は Windows, 今回は Linux で、同じ 24 セルを比べると 1 セルで購入数が違った。そのため、ルールベース 3 手法もこの端末で流し直した。

表 2: 実験の条件 (1 run=1 位置 ×4 エピソード)

学習	公開データ 21 日分 (約 77GB, 5 億行) → 学習データ 48,384 行 (広告主 1 社 ×1 ティック) 本家のコードと既定の設定, 乱数 seed=1 1 ステップ =100 行で 1 回更新 既定: BC・IQL 20,000, 他の 3 手法 100 ステップ
評価 (固定)	シミュレータは既定の設定, 乱数 seed=1 Linux, Python 3.9.16, CPU
比較	8 手法 (学習ベースは既定の設定で学習した重み) 位置 48× エピソード 0~3 (192 セル) 計 384 run
学習の条件	位置 0, 8, 16, 24, 32, 40× エピソード 0~3 (a) 乱数シード 2, 3 で学習した重み (b) CQL・TD3.BC を 20,000 ステップ学習した重み (c) シミュレータに同梱の学習済み重み 計 108 run

2.3 取った特徴量

評価で記録した量は REP001 と同じで、学習に関する量を足した (表 3)。

表 3: 取った特徴量

種類	記録した量
評価 (REP001 と同じ)	入札の強さ, 市場, 予算のベース, 落札の出身, CPA, 位置と他社, 規模
学習データ	日ごとの行数と欠損, 広告主ごとの平均の α ・支払い・実績 CPA
学習の経過	1 ステップごとの損失, 所要時間, 重みのハッシュ
重みの出どころ	結果ごとに, 手法・ステップ数・乱数シード

3 結果

データと学習 公開データ 21 日分 (5 億行) を取得でき、学習データ 48,384 行を作れた。欠損は、3 日分の終盤にある入札額の 62,153 行だけで、その行は落札していなかった。17 モデルがすべて学習でき、損失は最後まで有限であった。既定設定の 5 モデルは、学習し直すと同じ重みになった。学習の所要時間 (CPU) は、既定設定で 13~93 秒, 20,000 ステップの CQL が 429 秒, TD3.BC が 771 秒であった。BCQ は 1 ステップ約 0.57 秒で、20,000 ステップは約 3 時間の見込みのた




図 1: 既定設定の 8 手法の時系列 (192 セルの中央値または平均)。破線はルールベース, 点線は他 47 社の中央値。左: 実効の入札係数 α , 中: 予算に対する支払いの累計, 右: 落札数

め, 事前に決めた打ち切りに従って流さなかった。

評価の動作と規模感 486 run がすべて完走した。1 run は 7~8 並列で 152~176 秒, 最大メモリは約 2.9GB であった。bidding() 1 回の平均は, BC・IQL・CQL・TD3_BC が約 12ms, BCQ が 48ms (最大 240ms), ルールベースは 0.13~1.6ms であった。

8 手法の比較 表 4 と図 2 のとおり, score 合計は, Online LP, BCQ, BC, IQL, ABid, PID, TD3_BC, CQL の順であった。BCQ・BC・IQL は, Online LP の 0.92~0.94 倍であった。既定設定の CQL は, 全ティックで α が 0 で, 1 度も落札しなかった。TD3_BC は α が約 19 で (他 47 社の中央値は約 83), 192 セルの購入数の合計は 8 であった (図 1)。BCQ の α の中央値は, ティック 0~41 で 100 のまま変わらなかった。セル単位で Online LP を上回った割合は, BC 0.48, IQL 0.47, BCQ 0.45 であった。カテゴリ別の合計が最大だった手法は, Online LP が 3 つ, IQL, BCQ, BC が 1 つずつであった。ルールベース 3 手法の値は, REP001 (Windows) とほぼ同じであった (Online LP 1.49 と 1.51, PID 0.78 と 0.78)。論文の図 10 (目視の概算, ABid を 1.0) は Online LP 6.5~7, IQL 2.6~3, BC 2.3~2.5 で, 倍率は本結果と一致しない (原因は未確認)。

表 4: 既定設定の 8 手法 (48 位置 $\times$ 4 エピソード, 192 セル)

	score 合計	ABid 比	平均報酬	罰の割合	消化率
Online LP	0.247	1.51	28.8	0.39	0.75
BCQ	0.232	1.41	28.9	0.45	0.83
BC	0.229	1.40	28.4	0.44	0.77
IQL	0.228	1.39	27.9	0.44	0.74
ABid	0.164	1.00	25.8	0.85	0.93
PID	0.129	0.78	24.4	0.82	0.99
TD3_BC	0.0004	0.002	0.04	0.21	0.00
CQL	0	0	0	0	0.00

score 合計は 20000 で割った値。平均報酬はペナルティ前の購入数。罰の割合は CPA 超過のペナルティが掛かったセルの割合。消化率は予算消化率の平均。




図 2: 8 手法のスコア。左: 合計, 右: セルごとの分布 (symlog 軸)

学習の条件 表 5 と図 3 は, 6 位置 $\times$ 4 エピソード (24 セル) の平均 score である。同じ 24 セルで, Online LP は 23.4, PID は 15.5, ABid は 12.0 であった。CQL と TD3_BC は, 既定の 100 ステップでは 3 つの seed すべてで 0 で, 20,000 ステップでは 18.6 と 21.5 になった。BCQ (100 ステップ) は, seed 1・2 が 21.7, seed 3 が 0 であった。BC と IQL は, seed を変えても既定の 0.96~1.03 倍に収まった。同梱の重みは, BC と IQL では自前の重みの 0.81 倍・0.84 倍, BCQ では 1.06 倍であった。

表 5: 学習の条件を変えたときの平均 score (24 セル)

	seed 1	seed 2	seed 3	2 万ステップ	同梱
BC	20.5	21.2	20.4	(既定)	16.6
IQL	21.3	20.9	20.4	(既定)	17.8
CQL	0	0	0	18.6	17.9
BCQ	21.7	21.7	0	未実施	23.0
TD3_BC	0	0	0	21.5	19.5

seed 1~3 は既定のステップ数 (BC・IQL は 2 万, 他は 100)。




図 3: 学習の条件を変えたときの平均 score (24 セル)。破線はルールベース 3 手法

特徴量 episodes (1,944 行), ticks (93,312 行),

agents (93,312 行) の全数値列に、NaN・無限大はなかった。

以上より、実験の前に決めた達成条件 (REP002.md) を満たし、探索の目的は**達成**した。ただし、BCQ の 20,000 ステップは打ち切りの決まりで流しておらず、既定の成績が 0 の CQL と TD3_BC は、既定に対する比ではなく成績そのものを記録した。

4 結果から生まれた問い

本家の既定設定のまま学習すると、BC・IQL・BCQ は Online LP の 0.92~0.94 倍の score で、ABid と PID を上回った。CQL と TD3_BC は、既定の 100 ステップでは落札できず、20,000 ステップでは落札できた。BCQ は、seed 3 で score が 0 になった。BC・IQL・BCQ は、CPA 制約を入力にも報酬にも持たないが、ペナルティが掛かったセルの割合は 0.44~0.45 で、Online LP (0.39) に近かった。

まだ確かめていないが、既定の 100 ステップは学習には短すぎると考えられる。本家のコードに、試験用の短い値が残っている可能性がある。BCQ の seed 3 の 0 も、100 ステップでは学習が安定しないことの現れである可能性がある。また、BC と IQL がペナルティを受けにくかったのは、学習データの α (中央値 81) が他社の水準に近く、予算を使い切らない入札になったためである可能性がある。論文との倍率の違いは、基準にした ABid の成績が、論文より高いことから来ている可能性がある。

学習ベースの手法は、学習ステップ数をどこまで増やせば、乱数シードを変えても成績が揃うのかを知りたい。

REP003 探索：既存 8 手法を、どの設定で動かせば、以後の比較の相手にできるか

W001 20261009

サマリー

以後の比較の相手にする既存 8 手法（ルールベース 3、学習ベース 5）の、パラメータ設定を決めた。評価に使う日の score を見ずに、方策の出力（入札係数 α ）が学習の長さで乱数シードでどれだけ動くかを測って候補を決め、評価に使わない日（エピソード 4～7）で試した。ルールベースは本家の既定値のまま、学習ベースは 5 手法とも 30,000 ステップ・seed 1～3 の平均とし、5 手法とも、seed による score の幅が事前に決めた 10% 以内であった（BC 0.45%～TD3_BC 9.99%）。BCQ は状態によらず $\alpha = 100$ を出しており、ここから、学習ベースの手法と一定の α の入札との差が何から来るのかを知りたい、という問いが生まれた。

1 目的

REP002 で、本家の既定設定の CQL・TD3_BC が落札できなかったことを受けて、既存 8 手法を公平に動かせるパラメータ設定を決め、以後の比較のベースラインにする。

2 実験

2.1 対象のアルゴリズム

8 手法とも、入札額を「 $\alpha \times$ 価値」で決める。設定を決めるうえで関わる点（方策がログの α に引き寄せられるか、出力に上限があるか）を、表 1 にまとめる。

表 1: 対象の 8 手法（本家の実装。設定を決めるうえで関わる点）

PID・ABid・Online LP	学習しない。規則で α を決める
BC	ログの α との二乗誤差だけで学ぶ
IQL	報酬が大きかったログの α を、重く見て真似る
TD3_BC	二乗誤差 + Q 値の項
CQL	Q 値の傾きだけで α を動かす。ログに引き寄せる項は無い
BCQ	生成モデルが α の候補を作り、Q 値が最大のものを選ぶ。出力の上限は 100

2.2 実験環境

設定は、表 2 の 4 つの条件（実験の前に決めた）を満たすように決めた。score は、セル（位置 $\times$ エピソード）ごとの「CPA のペナルティ係数 $\times$ 獲得価値」である。

表 2: 設定を決めるときの条件（「公平」の定義）

F1	評価の日（エピソード 0～3）の score で選ばない
F2	学習ベースは、出力が落ち着いた重みを使う
F3	全手法に、同じデータと同じ決め方を使う
F4	変えるのは、理屈かデータから決まるものだけ

表 3: 実験の条件

固定	学習データ：公開データ 21 日分（48,384 行） 学習率などは本家の既定、CPU, Linux
出力の測定	学習データから抜いた 2,000 状態への α 5 手法 $\times$ seed 1～3 100～50,000 ステップの 8 時点（BCQ は 20,000 まで）
落ち着きの基準	状態ごとの α の差の平均が 5 以内 （以降の時点どうし、seed どうし）
候補を試す	30,000 ステップ、seed 1～3 エピソード 4～7 $\times$ 位置 0, 8, 16, 24, 32, 40 計 90 run
合格の基準	全 seed が落札する 3 seed の平均 score の幅が、平均の 10% 以内

2.3 取った特徴量

score のほかに、方策の出力そのものと、その内訳を記録した（表 4）。

表 4: 取った特徴量

種類	記録した量
方策の出力	α の平均、時点間の差、seed 間の差、ログの α との相関、上限への集中
出力の内訳	BCQ の生成モデルの出力、TD3_BC の損失の項ごとの傾き、CQL の Q 値が最大になる α
評価	score、予算消化率、評価中の α

3 結果

決めた設定 表 5 のとおりである。ルールベース 3 手法は、本家の既定値のままにした（評価の日の score で調整していない）。学習ベース 5 手法は、学習の長さだけを変え、5 手法とも 30,000 ステップにした。30,000 は、落ち着きの基準を満たした BC・IQL の、満たし始めのステップである。設定は research/src/baseline_params.json にまとめた。

表 5: 確定したベースラインの設定 (学習ベースは seed 1~3 の平均で報告する)

手法	学習の長さ	基準	但し書き
PID	—	—	既定値。調整していない
ABid	—	—	同上
Online LP	—	—	同上
BC	30,000 (既定 20,000)	満たす	30,000 と 50,000 の 1 組の比較による
IQL	30,000 (既定 20,000)	満たす	同上
CQL	30,000 (既定 100)	満たさない	出力の水準が学習の長さで動く
TD3_BC	30,000 (既定 100)	満たさない	Q 値の項が効かず、実質は BC
BCQ	30,000 (既定 100)	一定の出力	状態によらず $\alpha = 100$

方策の出力 学習データの状態への α の平均は、BC・IQL・TD3_BC では、到達したあと 82~86 の範囲にあった (ログの α の平均は 82)。100 ステップの時点では、BC 5.3, IQL 0.1, CQL -0.8, TD3_BC 17.8 であった。30,000 ステップと 50,000 ステップの出力の差は、BC 4.9, IQL 4.2, TD3_BC 10.3, CQL 21.0 であった。CQL は、 α の平均が 10,000 ステップで 91, 20,000 で 101, 50,000 で 73 と動いた。TD3_BC は、方策の損失のうち Q 値の項の傾きが、二乗誤差の項の 0.1%未満であった。BCQ は、1,000 ステップ以降、3 seed と、ほぼ全状態で 100.0 を出した。生成モデルの出力そのものが上限に張り付いていた。上限をログの α の 99% 点から決めた 300 に変えると、seed 1 つは 300 に張り付き、残りの 2 つは、生成モデルの出力がログの α と負の相関 (-0.42, -0.39) になったため、上限は既定の 100 のままにした。

候補を試した結果 表 6 のとおり、5 手法とも、全 seed が落札し、seed による score の幅は 10%以内であった。TD3_BC の幅は 9.99%で、基準との差は 0.01 ポイントであった。BCQ は、3 seed の結果が全セルで同じで、評価中の α は、予算が残っている間は 100.0 であった。実験の前に決めた合格の基準を、5 手法とも満たした (達成)。

表 6: 候補を試した結果 (エピソード 4~7, 6 位置, 24 セルの平均 score)

	seed 1	seed 2	seed 3	平均	幅
BC	21.02	21.05	20.95	21.01	0.45%
IQL	20.08	19.47	19.29	19.61	4.0%
CQL	19.09	19.24	18.86	19.06	2.0%
TD3_BC	17.99	18.59	19.87	18.82	9.99%
BCQ	17.53	17.53	17.53	17.53	0.0%

4 結果から生まれた問い

既定の 100 ステップで落札できなかった CQL・TD3_BC は、30,000 ステップでは、全 seed が落札し、seed による score の幅が 10%以内であった。評価中の

α の平均は、BC・IQL・CQL・TD3_BC の 12 個の重みで 83~91 に収まり、ログの α の平均 (82) に近かった。BCQ は、予算が残っている間、状態によらず $\alpha = 100$ を出した。24 セルの平均 score は、BC 21.0, IQL 19.6, CQL 19.1, TD3_BC 18.8, BCQ 17.5 であった。

学習ベースの 4 手法は、どれも「ログの α を真似る」のに近い方策になっていると考えられる。そうなら、手法どうしの score の差は、 α の水準のわずかな違いか、状態に応じた α の変え方の違いから来ている可能性がある。一定の α を出す BCQ が、BC の 0.83 倍の score を取っていることは、状態に応じて α を変えることの効果が、それほど大きくない可能性を示す。ただし、BCQ と BC は α の水準も違う (100 と 87) ので、この比較からは切り分けられない。また、CQL の score が学習の長さでどう変わるかは、確かめていない。

学習ベースの手法が、一定の α を出すだけの入札に対して持つ score の差は、 α の水準の違いによるのか、状態に応じて α を変えることによるのかを知りたい。